مستندات فنی FlowCheck — نسخه دوم

سامانه هوشمند آزمایش جریان‌های کاری وب | مسابقه ۲۰۲۶ buildX، مسئله ۴

نسخه سند: ۲٫۰ | تاریخ: ۱۰ اکتبر ۲۰۲۶ | مبنای وضعیت: مستند پیشین و گزارش‌های ارائه‌شده از Codex

۱. معرفی و دامنه محصول

FlowCheck یک برنامه تحت وب برای تبدیل هدف آزمایش به زبان طبیعی به سناریوهای اجرایی در مرورگر واقعی است. کاربر آدرس سایت و خواسته خود را وارد می‌کند؛ Planner سناریوها و انتظار هر یک را می‌سازد، کاربر در Smart Test Setup دامنه اجرا و داده‌های آزمایشی مجاز را بازبینی می‌کند، Executor با Playwright تعامل انجام می‌دهد و نتیجه با تکیه بر مشاهده و Assertionهای برنامه‌ریزی‌شده ثبت می‌شود. سپس شواهد تصویری، توضیح‌های تحلیلی، مراحل بازتولید و تاریخچه در اختیار کاربر قرار می‌گیرد.

محدوده نسخه دوم شامل آزمایش‌های متمرکز و چندسناریویی، تفکیک وضعیت اجرا از وضعیت سایت، ذخیره خودکار Run، ذخیره Suite قابل اجرای مجدد، Replay، بررسی مقایسه‌ای اجراهای سازگار، Pin اجراها و نمایش تصویریِ مبتنی بر بازکردن جزئیات است. FlowCheck جایگزین قطعی تمام آزمون‌های انسانی، امنیتی یا بار نیست.

۲. معماری کلان

معماری منطقی از React/Vite در سمت کاربر، API مبتنی بر FastAPI و Pydantic، لایه هماهنگی Agent، مرورگر Playwright/Chromium، سرویس بیرونی مدل زبانی از مسیر SQLite ،Router۹ و فضای ذخیره Artifact تشکیل شده است. استقرار نسخه قبلی از Docker Compose و Nginx/HTTPS استفاده می‌کرد. وجود هر نام منطقی مانند Planner یا Reporter به معنی وجود کانتینر مستقل برای آن نیست.

نقش واقعی/گزارش‌شده	جزء
فرم Smart Test Setup ،Workspace، کارت سناریو، گزارش، History و مقایسه	**React / Vite**
API، کنترل هویت/مالکیت، قرارداد ورودی/خروجی و هماهنگی عملیات	**FastAPI / Pydantic**
تبدیل هدف به سناریو و Assertions، طبقه‌بندی broad/focused	**Planner**
تعامل واقعی با DOM و ثبت مشاهدات و تصاویر	**Executor / Playwright**
پیگیری محدود موارد مبهم در چارچوب سقف اجرا	**Investigator**
تحلیل مشاهدات و تولید گزارش یا fallback مبتنی بر داده معتبر	**Analyzer / Reporter**
ماندگاری کاربران، Pin ،Suite ،Run و شواهد	**SQLite / Artifacts**
تأمین استنتاج مدل بیرونی؛ مدل اختصاصی روی سرور گزارش نشده	**LLM API/۹Router**

۳. چرخه اجرایی Agent و قرارداد وضعیت‌ها

۳،۱. دریافت هدف و برنامه‌ریزی

ورودی حداقلی شامل URL و هدف کاربر است. Planner ممکن است درخواست را focused (یک سناریو) یا broad (چند سناریوی مستقل) تشخیص دهد. در Smart Test Setup سناریوها پیش از اجرا به کاربر نشان داده می‌شوند و در صورت نیاز به ورود موفق، اطلاعات مرجع آزمایشی مجاز درخواست می‌شود. داده‌های منفی به‌صورت جداگانه تعریف یا تولید می‌شوند.

نکته صحت: در آخرین آزمون دو سایت Northline، مدل برای درخواست broad خروجی چندسناریویی با scope برابر focused تولید کرد و Pydantic با قاعده «focused scope requires exactly one scenario» آن را رد کرد. هر دو POST /api/test-plan با ۵۰۲ متوقف شدند. این یک ناسازگاری واقعی گزارش‌شده میان خروجی Planner و Schema است؛ رفع آن در گزارش تحویل‌شده هنوز اثبات نشده است.

۳،۲. اجرا و سنجش

Executor مراحل مرورگر را اجرا می‌کند و وضعیت قابل مشاهده را بررسی می‌کند. شرط «فرم ورود پنهان شد» به‌تنهایی برای تأیید احراز هویت کافی نیست؛ نسخه اصلاح‌شده از نشانه‌های ورود معتبر نظیر ناحیه حساب و دکمه Logout استفاده کرده است. در سناریوهای ورودی خالی، رد شدن احراز هویت باید از الزام HTML به required یا aria-invalid تفکیک شود: ممکن است تست اول PASS شود و نقص دسترس‌پذیری هنوز جداگانه وجود داشته باشد.

تعبیر	وضعیت سناریو
شواهد معتبر با انتظار برنامه‌ریزی‌شده سازگار است	**PASS**
شواهد معتبر ناسازگار با انتظار است	**FAIL**
مانع بیرونی یا پیش‌نیاز جلوی اجرا را گرفته است	**BLOCKED**
شواهد برای حکم معتبر کافی نیست	**INCONCLUSIVE**
سناریو هنوز اجرا نشده یا انتخاب نشده است	**NOT RUN**

وضعیت Agent Completed یا Failed جدا از نتیجه سناریوی وب‌سایت است. یک Run می‌تواند Agent Completed باشد ولی برخی سناریوهای هدف FAIL شوند. سناریوهای مختلف باید مستقل بمانند؛ تغییر نتیجه یک سناریو نباید نتیجه سناریوی دیگر را بازنویسی کند.

۳،۳. تحلیل و گزارش

Analyzer و Reporter باید بر شواهد تاییدپذیر Browser و Assertion تکیه کنند و علت احتمالی را از رخداد قطعی جدا کنند. برای خروجی نامعتبر مدل یا خطاهای تحلیل، مسیر fallback مبتنی بر داده معتبر مرورگر گزارش شده است. عبارت « HIGH severity» نباید صرفاً با FAIL شدن آزمون تعیین شود؛ شدت به اثر، شرایط و شواهد نیاز دارد. Screenshotها با عنوان معنادار و ارتباط دقیق با سناریو ذخیره می‌شوند.

۴. تجربه کاربری و قابلیت‌های نسخه دوم

نسخه بصری موسوم به Graphite Lab شامل تم روشن و تاریک، کارت‌های فشرده سناریو، حلقه/آیکون وضعیت، گزارش‌های قابل بازشدن، نمای تصویر تمام‌صفحه، History و Pin مالک‌محور است. بازخورد تصویری کاربر نشان می‌دهد بعضی صفحات هنوز شلوغ و متن‌محور بوده‌اند و برای اصلاح Information Architecture دستور جدید صادر شده است؛ نتیجه نهایی آن اصلاح در داده‌های این سند تأیید نشده است.

دایره پیشرفت درصدی واقعیِ هر سناریو در نسخه گزارش‌شده فعال نیست؛ API اجرای موجود رویدادهای مرحله‌به‌مرحله قابل اتکا منتشر نمی‌کند. بنابراین نشانگر indeterminate صادقانه است، نه درصد ساختگی. نمایش نموداری Compare برای Runهای دارای پوشش و شناسه سازگار معنی‌دار است؛ نبود تطابق نباید به‌صورت «باگ رفع شده» نمایش داده شود.

۵. تاریخچه، Replay، Suite و مقایسه

Run یک اجرای مستقل و ذخیره‌شده است؛ Saved Suite برنامه‌ای قابل استفاده مجدد است؛ Pin تنها یک ویژگی کاربرمحور برای برجسته‌کردن Run است. ثبت Run به کلیک ذخیره نیاز ندارد. تاریخچه فیلتر جست‌وجوی سایت، بازه زمانی و جریان تست را پشتیبانی می‌کند. Replay باید اجرای جدید با شناسه جدید ایجاد کند و اجرای تاریخی را تغییر ندهد.

مقایسه بر اساس هویت پایدار سناریو و قابل‌مقایسه بودن توقع آزمون انجام می‌شود. در نمونه دستی قدیمی، دو Run با پنج سناریوی هم‌ارز وضعیت‌های یکسان را نشان داده بودند؛ در بررسی UI اخیر دو Run منتخب غیرقابل‌مقایسه شناسایی شده‌اند، بنابراین نمایش تغییر سناریو برای آن جفت ادعای صحیحی نیست. نمای نموداری Compare طبق گزارش هنوز به آزمون تکمیلی با جفت مناسب نیاز داشته است.

۶. سایت‌های آزمایشی Northline

به جای اتکا به یک سایت دمو با حالت خطای پارامتری، دو سایت مستقل با ظاهر ورود یکسان ساخته شده‌اند: flowcheck-healthy.test و flowcheck-buggy.test. هر دو روی شبکه محلی Compose دارای نام داخلی مشخص‌اند و از روی میزبان فقط به ۱۲۷٫۰٫۰٫۱ با درگاه‌های ۸۱۸۱ و ۸۱۸۲ متصل بوده‌اند. اطلاعات نمایشی مشترک و ساختگی است. نام میزبان داخلی .test را نباید بدون پیکربندی مستقل، URL عمومی اینترنت معرفی کرد.

Buggy	Healthy	آزمون
موفق	موفق	**ورود با مشخصات صحیح**
به اشتباه پذیرفته می‌شود	رد می‌شود	**ورود با رمز عمداً غلط**
رد می‌شود	رد می‌شود	**ایمیل ناشناخته**
ناقص	درست	**اعتبارسنجی required ایمیل خالی**
درست	درست	**اعتبارسنجی رمز خالی**
دسترسی اشتباهاً حفظ می‌شود	نشست نامعتبر می‌شود	**خروج و دسترسی دوباره به /workspace**

این تفاوت‌ها در آزمایش مستقیم با مرورگر گزارش شده‌اند؛ ۲۸ تست مربوط به Demo و سیاست URL موفق و Chromium داخل کانتینر نیز رفتار رمز اشتباه و نقص Logout را تأیید کرده است. با این حال Agent هنوز نتوانسته این دو سایت را از ابتدا تا گزارش تست کند، چون در مرحله Planner متوقف شده است. بنابراین «کشف باگ توسط FlowCheck روی دو سایت» تا دریافت نتیجه E۲E معتبر، یک هدفِ تأییدنشده است.

۷. امنیت و مرزبندی محیط‌ها

کنترل SSRF برای URLهای هدف ضرورت بنیادی دارد. در محیط توسعه، originهای دقیق دو سایت داخلی به allowlist اضافه شده‌اند؛ طبق گزارش نه شبکه خصوصی به طور کلی آزاد شده و نه تنظیمات Production تغییر کرده‌اند. تأیید originها، DNS و Compose در همان محیط محلی گزارش شده است. راهنمای OWASP تأکید می‌کند Allowlist، بررسی تبدیل/Resolve آدرس و محدودسازی مسیرهای دسترسی نقش مکمل دارند [۵].

اطلاعات آزمایشیِ معتبر تنها برای آزمون مجاز وارد می‌شوند. Redaction باید مقدار واقعی رمز و داده حساس را حذف کند اما متن توضیحی عادی مانند «Password is invalid» را تخریب نکند. گزارش تثبیت اخیر، رفع False Positive رداکشن و عدم ذخیره داده‌های حساب آزمایشی در plan/report/history را گزارش کرد. آزمون مالکیت Screenshot، Run و Pin در Backend اهمیت دارد؛ پیاده‌سازی Pin مالک‌محور و تست آن گزارش شده ولی ممیزی جامع نفوذ یا انطباق رسمی انجام نشده است.

متن سایت مقصد ورودی غیرقابل‌اعتماد است و نباید به‌عنوان دستور دارای اختیار اجرای Agent پذیرفته شود. سناریوهای دمو فقط با هویت ساختگی اجرا می‌شوند. سایت عمدی معیوب نباید به دیتابیس واقعی یا شبکه حساس دسترسی پیدا کند.

۸. ساختار داده و نگهداری شواهد

داده‌های منطقی شامل حساب کاربر، درخواست و برنامه آزمون، سناریو و Assertions، نتیجه مستقل سناریو، وضعیت Agent، Screenshot و Artifact، تاریخچه Saved Suite، Run، ارجاع Replay/parent run و وضعیت Pin است. SQLite برای محصول اولیه استفاده شده؛ نام دقیق جدول‌ها و migrationها باید با سورس نسخه تحویلی تأیید شود.

نسخه تاریخی استقرار از Volumeهای flowcheck_prod_data و flowcheck_prod_artifacts استفاده می‌کرد؛ وجود و مسیر آن‌ها در سرور فعلی باید مجدداً بررسی شود. عملیات انتشار نباید volumeها را حذف کند. سیاست retention و سقف شواهد برای توسعه تجاری هنوز نیازمند طراحی و اندازه‌گیری است.

۹. استقرار و زیرساخت

در مستند پیشین، VPS با Ubuntu Server ۲۴.۰۴، دو vCPU، چهار گیگابایت RAM، حدود ۴۰ گیگابایت دیسک، مسیر /opt/flowcheck و دامنه https://flowcheck-demo.iddns.ir/ توصیف شده بود. این مشخصات داده‌های تاریخی هستند و وضعیت منابع پس از استقرار جدید از این گفتگو قابل تأیید نیست.

آخرین دستور کار ارسالی به Codex، رفع ناسازگاری Planner و سپس انتشار ایمن V۲ و دو سایت Northline روی VPS بوده است؛ گزارش تکمیل آن دستور در اطلاعات ارائه‌شده موجود نیست. بنابراین سند نه استقرار نهایی V۲ را تأیید می‌کند و نه URL عمومی سایت‌های آزمایشی را می‌سازد. برای نهایی‌سازی، فایل Compose و Reverse Proxy، نسخه imageها، DNS/TLS، سلامت API و آزمایش E۲E روی همان Revision باید استخراج شوند.

۱۰. آزمون‌ها و شواهد اندازه‌گیری

برداشت صحیح	شاهد گزارش‌شده	گام/آزمایش
داده تاریخی، نه آخرین وضعیت	۷۵ تست Backend؛ چهار سناریوی محلی	**نسخه قدیمی**
E۲E معتبر روی دموی قبلی با Provider و Chromium	۱۵۶ تست Backend موفق؛ Broad: پنج PASS؛ Focused: یک PASS	**تثبیت فنی V۲**
۱۵۷ در گزارش آمده؛ بازاجرای نهایی به‌دلیل نبود pytest انجام نشد	چهار تست ui-model؛ build موفق؛ ۱۵۷ Backend در اجرای قبلی	**بازطراحی UI**
عدم صدور PASS کاذب برای شرط ضعیف قدیمی	چهار PASS و یک INCONCLUSIVE	**Replay Suite قدیمی**
سلامت Fixture و URL policy، نه موفقیت Agent	۲۸ تست Playwright/URL policy موفق	**سایت‌های دوگانه Northline**
هیچ سناریو یا Screenshot متعلق به Agent برای این دو اجرا تولید نشد	دو ۵۰۲ ناشی از scope چندسناریویی focused	**Agent روی Northline**

تعداد ۱۵۶، ۱۵۷ و ۲۸ به اجراها/مجموعه‌های متفاوت تعلق دارند؛ نباید بدون اثبات عدم همپوشانی با هم جمع شوند. PASS سناریو به معنی موفقیت «رفتار مورد انتظار» است و لزوماً به معنی نبود هیچ نقص دیگر در سایت نیست.

۱۱. شکست‌های شناخته‌شده و مدیریت خطا

الف) خروجی Planner درخواستی broad را به چند سناریو با scope focused تبدیل کرده و Pydantic آن را رد کرده است؛ این مسئله دست‌کم در دو آزمون Northline مانع کل جریان شد. ب) پیش‌تر درخواست‌های ۵۰۲ بدون تشخیص قطعی علت دیده شده بودند؛ نباید همه آن‌ها را به یک علت نسبت داد. ج) در بعضی Replayهای قدیمی Analyzer/Reporter به مسیر deterministic fallback برگشته‌اند. د) API فعلی Progress عددی مستقل هر سناریو عرضه نکرده است. ه) مقایسه تاریخی فقط برای سناریوهای هم‌معنا صحیح است.

راهکار مهندسی پیشنهادی برای Planner، نگه داشتن اعتبارسنجی سخت‌گیرانه و افزودن بازیابی محدود، امن و عمومی برای پاسخ ناسازگار است؛ بدون special-case دامنه یا تغییر انتظار پس از مشاهده نتیجه. این راهکار تا زمانی که در کد و E۲E تست نشود، صرفاً پیشنهاد است.

۱۲. نقشه راه آزمون و بهره‌برداری

• گام نخست: اصلاح عمومی scope در Planner و پوشش regression برای focused/broad و بازاجرای E۲E روی هر دو Northline.

• گام دوم: تثبیت رابط visual-first، آزمودن نمودار Compare با Runهای واقعاً هم‌ارز و تضمین کم‌تر بودن نمای نخست.

• گام سوم: استقرار مرحله‌ای V۲ روی VPS با TLS، Rollback، Backup و مالکیت شواهد؛ ثبت نتیجه عمومی با تاریخ و revision.

• گام چهارم: جمع‌آوری شاخص‌های پایداری، مصرف Provider، هزینه اجرای قابل استفاده و سنجش روی سایت‌های مجاز متنوع.

۱۳. روش اجرای نمایشی و ارزیابی توسط داور

داور باید بتواند دو صفحه Northline با ظاهر یکسان را باز کند، یک prompt مشترک برای ورود صحیح و نامعتبر به FlowCheck بدهد، سناریوهای Planner را پیش از اجرا ببیند، با حساب ساختگی اجرای مجاز را شروع کند، و برای هر سناریو نتیجه و Screenshot مرتبط را بررسی کند. در سایت معیوب، یک رفتار مشخص مانند پذیرش رمز غلط باید به عنوان FAIL در برابر انتظار رد ورود ثبت شود. این یک سناریوی دمو با نقص عمدی است؛ کشف ناشناخته در سایت تجاری محسوب نمی‌شود.

تا وقتی گزارش E۲E پس از رفع Planner ارائه نشود، این مسیر «سناریوی هدف برای مسابقه» است، نه دموی تأییدشده End-to-End. در ارائه باید هنگام نمایش Run قدیمی، آن را با اجرای زنده اشتباه نگرفت.

۱۴. معیارهای پذیرش و شاخص‌های فنی

معیار سنجش	شاخص
سازگاری دامنه focused/broad، وجود انتظار معتبر و پوشش سناریوهای مورد درخواست	**درستی برنامه‌ریزی**
Precision/Recall/FPR/FNR در مقایسه با برچسب انسانی	**دقت نتیجه**

یا Fixture مشخص	
Runهای دارای سناریوی اجراشده و گزارش معتبر تقسیم بر Runهای آغازشده	**نرخ E۲E قابل استفاده**
تکرار آزمون یکسان و ثبات نتیجه تحت شرایط کنترل‌شده	**پایداری**
زمان تا گزارش، توکن مدل، مدت مرورگر و ذخیره داده	**زمان/هزینه**
تست SSRF، مالکیت Run/Artifact، عدم افشای Credentials	**امنیت**
HTTPS، سلامت Service، داده ماندگار، Rollback آزمایش‌شده	**استقرار**

هیچ درصد دقت کشف نقص یا ظرفیت همزمانی عمومی از آزمایش‌های فعلی استنتاج نمی‌شود. سنجش چنین اعدادی به مجموعه آزمون بزرگ‌تر و برچسب مرجع نیاز دارد.

۱۵. جمع‌بندی و مرز شواهد

FlowCheck V۲ از یک نمونه تک‌سناریویی فراتر رفته و چرخه چندسناریویی، بازبینی پیش‌نیازها، اجرای واقعی مرورگر، گزارش تصویری و امکانات نگهداری و مقایسه Runها را در گزارش‌های توسعه نشان داده است. دو Northline مستقل نیز برای دموی مقایسه‌پذیر سالم/معیوب ساخته و مستقلاً آزموده شده‌اند. بزرگ‌ترین شکافِ تاییدشده این لحظه، ناسازگاری خروجی Planner در اجرای broad روی دو هدف جدید است. در کنار آن، نتیجه استقرار نهایی عمومی نسخه جاری و بلوغ UI مقایسه نیازمند گزارش آزمون تازه هستند. این مرزبندی باعث می‌شود مستند فنی دقیق و قابل دفاع باقی بماند.

۱۶. منابع رسمی و مدارک داخلی

- [۱] Playwright Python — Introduction: https://playwright.dev/python/docs/intro
- [۲] Playwright — Screenshots: https://playwright.dev/python/docs/screenshots
- [۳] FastAPI — Behind a Proxy: https://fastapi.tiangolo.com/advanced/behind-a-proxy/
- [۴] Pydantic — Models and Validation: https://docs.pydantic.dev/latest/concepts/models/
- [۵] OWASP — SSRF Prevention Cheat Sheet: https://cheatsheetseries.owasp.org/cheatsheets/Server_Side_Request_Forgery_Prevention_CheatSheet.html_
- [۶] Docker — Compose: https://docs.docker.com/compose/
- [۷] Docker — Compose down and volumes: https://docs.docker.com/reference/cli/docker/compose/down/
- [۸] مستند فنی اولیه کاربر، نسخه ۱٫۰، ۹ اکتبر ۲۰۲۶ (۲۶ صفحه).
- [۹] گزارش‌های Codex: تثبیت ۱۵۶ تست، بازطراحی Graphite Lab و ۱۵۷ تست قبلی، ۲۸ تست دو سایت Northline و شکست Planner.
- [۱۰] اسکرین‌شات‌های UI و گزارش‌های اجرای واقعی ارائه‌شده در گفت‌وگو؛ برای اثبات نسخه تحویلی نیازمند ثبت commit/revision هستند.

یادداشت صدور سند: برای ادعای تطابق ۱۰۰٪ با برنامه نهایی، لازم است کد و Commit آخر، خروجی API Schema، وضعیت Docker در سرور و E۲E تازه از دو سایت به این سند ضمیمه شوند. این نسخه همه واقعیت‌های موجود در گزارش‌های دریافت‌شده را از فرضیه‌های فنی جدا کرده است.